

Previsão do Retorno do Café Arábica (KC=F) com Redes LSTM e Variáveis Climáticas Regionais de Minas Gerais

Euler G. Rocha¹, Antonio A. Ambrosio¹, Marcos R. Ribeiro¹

¹Instituto Federal de Minas Gerais (IFMG) – Campus Bambuí
Bambuí – MG – Brasil

eulergomesrocha@gmail.com

Abstract. *We forecast the one-day-ahead log-return of arabica coffee futures (KC=F) with LSTM networks that combine market indicators and daily climate observations from four INMET stations in the main producing regions of Minas Gerais, Brazil. Using a leakage-controlled walk-forward protocol (expanding window, embargo, per-fold scaling) and a five-seed ensemble, we benchmark against a random walk, ARIMA and GARCH, and test significance with the Diebold–Mariano test. No model significantly beats the random walk — an honest result for a daily commodity return. Adding climate reduces RMSE marginally, and a per-city representation outperforms a production-weighted aggregate, suggesting that regional granularity carries useful signal, albeit within seed noise.*

Resumo. *Prevemos o log-retorno de um dia à frente dos futuros de café arábica (KC=F) com redes LSTM que combinam indicadores de mercado e observações climáticas diárias de quatro estações do INMET nas principais regiões produtoras de Minas Gerais. Empregando um protocolo walk-forward com controle de vazamento (janela expansiva, embargo, normalização por fold) e um ensemble de cinco sementes, comparamos com random walk, ARIMA e GARCH, e testamos significância com Diebold–Mariano. Nenhum modelo supera o random walk de forma significativa — resultado honesto para retornos diários de commodity. Adicionar clima reduz marginalmente o RMSE, e a representação por cidade supera a agregação ponderada por produção, sugerindo que a granularidade regional carrega sinal útil, ainda que dentro do ruído de semente.*

1. Introdução

O Brasil é o maior produtor e exportador mundial de café, e Minas Gerais responde pela maior parte da produção nacional de café arábica [CONAB 2025]. A volatilidade do preço da commodity afeta diretamente produtores, cooperativas e exportadores, de modo que previsões confiáveis podem apoiar decisões ao longo de toda a cadeia. Diferentemente da maioria das abordagens de previsão financeira, que se apoiam apenas em indicadores de mercado, eventos climáticos — geadas, secas e extremos de temperatura — estão entre os mais fortes determinantes da oferta e, portanto, do preço do café.

Este trabalho investiga se a incorporação de variáveis climáticas regionais melhora a previsão do retorno diário dos futuros de café arábica (contrato KC=F, negociado na ICE) por meio de redes *Long Short-Term Memory* (LSTM). As contribuições são: (i) a

construção de um conjunto de dados que alinha o preço do KC=F, o câmbio BRL/USD e observações diárias de quatro estações automáticas do INMET nas regiões cafeeiras de Minas Gerais; (ii) um protocolo de avaliação temporal rigoroso, com controle explícito de vazamento e teste de significância; e (iii) uma análise honesta da contribuição do clima, incluindo uma comparação entre representar o clima *por cidade* (granularidade regional) ou como um *agregado ponderado pela produção*.

Antecipamos o principal achado: em log-retorno diário, nenhum modelo (LSTM, ARIMA ou GARCH) supera o random walk de forma estatisticamente significativa, o que é esperado em um mercado próximo à eficiência. Ainda assim, a adição de clima reduz marginalmente o erro e melhora o acerto direcional, e a granularidade por cidade se mostra preferível à agregação ponderada por produção.

2. Materiais

2.1. Fontes de dados

O preço de fechamento diário do KC=F (em USD/lb) e a taxa de câmbio BRL/USD foram obtidos via *yfinance* (Yahoo Finance). As variáveis climáticas vêm da rede de estações automáticas do INMET (BDMEP) [INMET 2025], consolidadas de frequência horária para diária. Foram usadas quatro estações, representando três regiões produtoras (Tabela 1).

Tabela 1. Estações INMET utilizadas e respectivas microrregiões.

Cidade	Código	Altitude	Região
Varginha	A515	942 m	Sul de Minas
Machado	A567	871 m	Sul de Minas
Patrocínio	A523	931 m	Cerrado Mineiro
Manhuaçu	A556	674 m	Matas de Minas

De cada estação retêm-se temperatura média, máxima e mínima do ar, precipitação total, radiação solar global, umidade relativa média, velocidade e rajada do vento, além de um indicador de risco de geada (temperatura mínima $< 0^{\circ}\text{C}$) e uma medida de *graus-frio* acumulados. O conjunto final cobre 1.763 pregões entre 31/12/2018 e 30/12/2025.

2.2. Análise exploratória

O nível do preço é fortemente não estacionário (ADF $p = 0,80$), enquanto o log-retorno $r_t = \ln(P_t/P_{t-1})$ é estacionário (ADF $p \approx 0$), o que motiva modelar o retorno. Os log-retornos são quase simétricos (assimetria 0,08) e levemente leptocúrticos (curtose em excesso 0,74), com volatilidade anualizada de 35,9%. A autocorrelação da *média* dos retornos é fraca (ACF/PACF dentro das bandas, Figura 1), mas a dos retornos ao quadrado é significativa e persistente, evidência de *volatility clustering*.

Eventos de risco de geada são raros e concentrados no inverno, sobretudo em Patrocínio (19 dias) e Varginha (12), contra Machado (3) e Manhuaçu (1) — 23 dias com pelo menos uma estação em risco na amostra. A correlação linear contemporânea entre clima e log-retorno é praticamente nula; contudo, o retorno médio nas semanas seguintes




Figura 1. ACF e PACF do log-retorno: pouca autocorrelação linear na média, sugerindo ordens baixas de ARIMA e ganho preditivo, se houver, em estrutura não linear/exógena.

a um dia de risco de geada supera o de dias normais, sugerindo um efeito *defasado* e não instantâneo (Figura 2). Isso justifica o uso de janelas temporais e de variáveis climáticas acumuladas.




Figura 2. Preço do café com dias de risco de geada destacados. Episódios (notadamente em 2021) coincidem com movimentos de alta, sugerindo reprecificação defasada da oferta futura.

3. Metodologia

3.1. Alvo e atributos

O alvo é o log-retorno de um dia à frente. Além do próprio retorno e do retorno do câmbio, computam-se atributos de mercado (volatilidades de 5 e 21 dias, média móvel de 10 dias) e de sazonalidade (sin e cos do dia do ano). Avaliam-se quatro configurações de atributos: (a) apenas mercado (sem clima); e três formas de incorporar o clima — (b) **Opção B**, clima bruto *por cidade* (formato *wide*, cada estação com suas colunas); (c) clima defasado/acumulado (risco de geada agregado e graus-frio em janelas de 30 dias); e (d) **Opção C**, em que cada variável climática é substituída por uma única *média ponderada pela produção* das regiões. Os pesos derivam da participação da produção de

arábica de Minas Gerais (Sul de Minas $\approx 55\%$, Matas de Minas $\approx 25\%$, Cerrado Mineiro $\approx 15\%$; fontes IBGE e EMATER-MG), resultando em Varginha 0,29, Machado 0,29, Manhuaçu 0,26 e Patrocínio 0,16.

3.2. Protocolo de validação temporal

Cada amostra é uma janela de $\text{LOOKBACK} = 45$ dias de atributos que prevê o retorno do dia seguinte. Usa-se validação *walk-forward* com janela de treino *expansiva* (5 folds a partir de 50% dos dados). Entre treino e teste aplica-se um *embargo* de 45 dias, garantindo que nenhuma janela de teste contenha dias já vistos no treino. Em cada fold, o `StandardScaler` e a seleção de atributos são ajustados *apenas* no núcleo de treino (85% inicial; os 15% finais servem de validação para *early stopping*), eliminando vazamento.

3.3. Modelo e robustez

A rede é uma LSTM [Hochreiter and Schmidhuber 1997] de uma camada (48 unidades, *dropout* 0,2) seguida de uma camada linear, otimizada com Adam [Kingma and Ba 2015] ($\text{lr} = 10^{-3}$, *weight decay* 10^{-4}) e *early stopping*. Para controlar o efeito da inicialização aleatória, cada configuração é treinada com **5 sementes por fold** e avaliada como *ensemble* (média das previsões); reporta-se também a dispersão do RMSE entre sementes.

3.4. Baselines e métricas

Comparamos com três baselines sob o mesmo protocolo e nos mesmos dias-alvo: **random walk** ($\hat{r}_t = 0$), **ARIMA** [Box and Jenkins 1976] (ordem escolhida por AIC no treino, previsão recursiva de um passo sem *refit*) e **GARCH(1,1)** [Bollerslev 1986] como baseline de *volatilidade*. As métricas de nível são RMSE, MAE, sMAPE, MASE [Hyndman and Koehler 2006] e acurácia direcional; a significância estatística é avaliada pelo teste de Diebold–Mariano (DM) [Diebold and Mariano 1995], com a convenção $\text{DM} < -1,96$ indicando modelo significativamente melhor que a referência. A seleção de atributos usa a importância de um *Random Forest* [Breiman 2001] treinado dentro do fold, reportando-se a estabilidade (frequência no top-12 entre os folds).

4. Resultados e Discussão

A Tabela 2 resume o desempenho. Random walk e ARIMA empatam em RMSE (0,02325), confirmando a expectativa da análise exploratória de que a média dos retornos é quase imprevisível. A LSTM apenas com mercado é *significativamente pior* que o random walk ($\text{DM}_{\text{oos}} = 2,51$). A inclusão de clima bruto por cidade (Opção B) reduz o RMSE para 0,02345, recupera o empate com o random walk ($\text{DM}_{\text{oos}} = 1,12$, não significativo) e é a única configuração de LSTM com acurácia direcional acima do acaso (0,502).

Granularidade regional (B vs. C). O clima *por cidade* (0,02345) supera o *agregado ponderado por produção* (0,02354). Ou seja, colapsar as quatro estações em uma única série ponderada descarta sinal útil: a resolução regional — provavelmente por refletir microclimas e a heterogeneidade dos eventos de geada entre regiões — é preferível, mesmo com mais atributos a estimar.

Tabela 2. Desempenho médio (walk-forward, ensemble de 5 sementes). RMSE e MAE em log-retorno. As colunas DM/RW e DM/ARIMA trazem a estatística de Diebold–Mariano *out-of-sample* contra o random walk e o ARIMA (DM > 1,96 indica modelo pior que a referência).

Modelo	RMSE	MAE	MASE	DirAcc	DM/RW	DM/ARIMA
RandomWalk	0,02325	0,01814	0,724	0,008	—	—
ARIMA	0,02325	0,01814	0,724	0,501	−0,11	—
LSTM só-mercado	0,02356	0,01837	0,734	0,475	2,51	2,44
LSTM +clima cidade (B)	0,02345	0,01836	0,733	0,502	1,12	1,13
LSTM +clima defasado	0,02346	0,01829	0,730	0,493	1,55	1,64
LSTM +clima pond. (C)	0,02354	0,01840	0,735	0,460	1,62	1,65

Robustez à inicialização. A Figura 3 mostra a distribuição do RMSE entre sementes. A dispersão média entre sementes ($\approx 0,0002$) é da *mesma ordem* do espalhamento entre configurações ($\approx 0,0001$). Portanto, embora o clima reduza o RMSE de forma consistente na direção, o ganho é pequeno e não robusto ao ruído de inicialização — coerente com a não significância do teste DM. Este é um alerta metodológico importante: sem *ensembling* de sementes, diferenças dessa magnitude poderiam ser reportadas como efeitos espúrios.




Figura 3. RMSE por semente ($N = 5$) por configuração. A variabilidade entre sementes é comparável às diferenças entre configurações.

Volatilidade. O GARCH(1,1) não superou consistentemente um benchmark de variância constante (QLIKE médio $-6,508$ vs. $-6,518$; GARCH vence em 2 de 5 folds). Assim, embora haja *clustering* de volatilidade, ele é difícil de explorar em previsão de um passo neste período.

Atributos selecionados. A seleção dentro do fold é estável: além dos atributos de mercado (ret_cafe, sma_10, vol_5, vol_21, ret_cambio) e da sazonalidade (sin_doy), a única variável climática presente no top-12 em *todos* os folds é a umidade relativa de Manhauçu; logo abaixo aparecem temperatura de Patrocínio e precipitação de Manhauçu. Isso indica que, quando o clima contribui, ele o faz por estações específicas — reforçando o achado de que a granularidade regional importa.

Discussão. A Figura 4 sintetiza MASE e acurácia direcional. O conjunto de evidências aponta para um mercado próximo à eficiência na média diária [Fama 1970]: nem modelos lineares (ARIMA) nem não lineares (LSTM) batem o random walk de forma significativa. A contribuição do clima existe, mas é marginal e não robusta. Do ponto de vista agro-informático, o resultado relevante é que a *forma* de representar o clima regional altera o desempenho, e que a resolução por cidade preserva sinal que a agregação destrói.




Figura 4. MASE (menor é melhor) e acurácia direcional por modelo. Todas as LSTM ficam próximas do random walk; apenas a Opção B ultrapassa o acaso na direção.

5. Conclusão

Apresentamos um estudo rigoroso e reproduzível de previsão do retorno diário do café arábica combinando mercado e clima regional de Minas Gerais. Sob um protocolo temporal com controle de vazamento, baselines obrigatórios, teste de significância e *ensembling* de sementes, nenhum modelo supera o random walk de forma significativa. Ainda assim, o clima reduz marginalmente o erro e melhora o acerto direcional, e a representação *por cidade* supera a agregação ponderada por produção, evidenciando que a granularidade regional carrega sinal útil. Como trabalhos futuros, destacam-se a busca de hiperparâmetros dentro do fold, horizontes de previsão mais longos (onde efeitos climáticos defasados podem ser mais visíveis) e a avaliação por métricas econômicas (simulação de estratégia direcional).

Agradecimentos

Ao IFMG – Campus Bambuí pelo apoio. Aos provedores dos dados públicos INMET e Yahoo Finance.

Referências

- Bollerslev, T. (1986). Generalized autoregressive conditional heteroskedasticity. *Journal of Econometrics*, 31(3):307–327.
- Box, G. E. P. and Jenkins, G. M. (1976). *Time Series Analysis: Forecasting and Control*. Holden-Day.
- Breiman, L. (2001). Random forests. *Machine Learning*, 45(1):5–32.
- CONAB (2025). Acompanhamento da safra brasileira de café. Companhia Nacional de Abastecimento. Disponível em: <https://www.conab.gov.br/info-agro/safras/cafe>.

- Diebold, F. X. and Mariano, R. S. (1995). Comparing predictive accuracy. *Journal of Business & Economic Statistics*, 13(3):253–263.
- Fama, E. F. (1970). Efficient capital markets: A review of theory and empirical work. *The Journal of Finance*, 25(2):383–417.
- Hochreiter, S. and Schmidhuber, J. (1997). Long short-term memory. *Neural Computation*, 9(8):1735–1780.
- Hyndman, R. J. and Koehler, A. B. (2006). Another look at measures of forecast accuracy. *International Journal of Forecasting*, 22(4):679–688.
- INMET (2025). Banco de dados meteorológicos (bdmep). Instituto Nacional de Meteorologia. Disponível em: <https://bdmep.inmet.gov.br>.
- Kingma, D. P. and Ba, J. (2015). Adam: A method for stochastic optimization. In *International Conference on Learning Representations (ICLR)*.